

Práctica 1

Introducción

Eres un programador recientemente contratado en una empresa EC durante el periodo de periodo de prueba. La empresa EC recibe muchos contratos y se preocupa por la calidad de sus resultados. Para validar tu competencia como programador, EC ha diseñado una prueba que tienes que entregar y ha colocado a un programador senior para validar tu resultado.

Una empresa de análisis estadístico para la política AE ha solicitado un programa para extraer información de Wikipedia y validar su veracidad, dado que se sabe que Wikipedia es abierta a edición pública, AE quiere asegurarse de que datos estadísticos que la propia empresa ha obtenido sobre diversos países no sean alterados por nadie.

La empresa EC ha decidido aprovechar esta oportunidad para probar al nuevo empleado. Has de extraer varios datos estadísticos básicos desde páginas web de Wikipedia sobre países e integrarlos en una clase de Python para su posterior uso en un sistema automático de corrección de datos de Wikipedia.

Desarrollo de la práctica

El estudiante debe implementar la clase **WikipediaAnalytics** dentro de un único fichero llamado **WikipediaAnalytics.py**. Este fichero contiene un **esqueleto inicial** con varios métodos definidos. A continuación, se detallan las diferentes partes de la clase y las consideraciones a tener en cuenta.

1. Constructor de la clase

El constructor recibirá una **lista de rutas de ficheros HTML**, correspondientes a páginas locales de Wikipedia. El alumno debe:

- Guardar esta lista como un atributo de la clase.
- Preparar un atributo donde más adelante se almacenará el **DataFrame resultante** del scraping.

2. Método scrap

El método scrap será el encargado de:

1. **Leer y procesar cada fichero HTML** incluido en la lista.
2. Extraer de cada país los siguientes datos (de la tabla resumen):
 - Nombre del país
 - Latitud de la capital (en grados decimales)
 - Longitud de la capital (en grados decimales)
 - Área del país (km²)
 - Porcentaje de agua

- Población
 - Densidad
 - PIB
 - Fecha del último evento histórico
3. Con los datos extraídos se debe construir un **DataFrame de pandas**, con:
- **Una fila por país**
 - **Una columna por cada atributo**
 - Los **tipos de datos** establecidos:
 - **nombre** → *string*
 - **latitud, longitud, área, % agua, población, densidad, PIB** → *float*
 - **fecha del último evento** → *fecha (datetime64 de pandas)*
4. El DataFrame final deberá seguir **el mismo formato** que el DataFrame de ejemplo incluido en la práctica.

El método debe almacenar el DataFrame como atributo de la clase.

Ejemplo de datos del DataFrame para tres países:

	Country Name	Area (KM^2)	Water (%)	Population (hab.)	Density (hab./km^2)	GDP (\$)	Last Event Date	Latitude (°)	Longitude(°)
0	Serbia	88361.0	NaN	6690887.0	115.00	4,77E+16	03/06/2006	44.818	20.457
1	Polonia	312696.0	2.60	41026068.0	123.20	8,42E+17	29/12/1989	52.230	21.011
2	España	505944.0	1.04	49570725.0	97.47	1,73E+18	29/12/1978	40.417	-3.703

Fórmula de conversión a grados decimales (para Word)

Las coordenadas aparecen en Wikipedia en notación de Grados, Minutos y Segundos y la necesitamos en formato decimal de grados. Para transformar el formato aplicamos la siguiente formula:

$$\text{Grados decimales} = \text{Grados} + \frac{\text{Minutos}}{60} + \frac{\text{Segundos}}{3600}$$

Si la coordenada está en el hemisferio **Sur (S)** o **Oeste (W / O)**, el valor resultante debe ser **negativo**.

3. Métodos de análisis

La clase incorpora tres métodos cuyo propósito es **procesar el DataFrame** obtenido. El alumno debe completar su implementación, sin modificar las firmas dadas. Estos métodos permiten:

- **Seleccionar filas** según los parámetros proporcionados.
- **Seleccionar columnas específicas** del DataFrame.
- **Calcular operaciones agregadas** (mínimo, máximo o media) sobre una columna numérica.

La lógica interna dependerá de la firma exacta definida en el esqueleto.

4. Restricciones y consideraciones

Lista de restricciones que hay que tener en cuenta a lo largo del desarrollo de la práctica:

- No cambiar nombres de métodos, parámetros ni estructura.
- Los datos deben normalizarse para asegurar que todos los atributos numéricos son **float**.
- Las coordenadas deben convertirse correctamente a **grados decimales** con signo según hemisferio.
- La fecha debe convertirse a tipo **pandas datetime**.
- Se pueden añadir funciones auxiliares para limpiar texto, convertir números, procesar coordenadas, etc.
- El fichero será validado mediante:
 - Un **notebook público**.
 - Un **notebook oculto** con pruebas adicionales.

Método de evaluación

La evaluación de la práctica se realizará siguiendo los criterios descritos a continuación:

1. Modalidad de realización

- La práctica es **individual**, la detección de copia entre estudiantes implicará una práctica suspendida para ambos participantes con un cero.
- Cada estudiante debe elaborar su propia solución.

2. Material a entregar

El alumno deberá enviar:

- El fichero **WikipediaAnalytics.py** con la implementación completa de la clase.

- Opcionalmente, un fichero **README.py** si necesita explicar alguna consideración especial, como:
 - Configuración necesaria para reproducir el funcionamiento.
 - Casos excepcionales detectados en el scraping.
 - Limitaciones justificadas.

No es necesario entregar ningún otro fichero.

3. Entorno de evaluación

- El archivo **WikipediaAnalytics.py** será evaluado en un entorno **Google Colab**, importado por el notebook de verificación.
- El fichero será colocado en el **directorio inicial** del entorno de Colab antes de ejecutarse junto a los ficheros de HTML de las páginas de Wikipedia.

4. Reglas de ejecución

- El sistema ejecutará el código directamente desde el notebook de verificación proporcionado en la carpeta de la práctica.
- Si durante la ejecución del notebook de verificación **se produce un error, excepción**, o el sistema **no funciona correctamente**, la práctica será **automáticamente suspendida con una calificación de 0**.
- Solo las prácticas que ejecuten el notebook sin fallos pasarán a la siguiente fase de evaluación.

Ejemplo de resultado con el jupyter notebook de validación:

🔗 Testing select_row_by_value...

- ✓ select_row_by_value finds an existing row.
- ✓ select_row_by_value returns None when no match exists.
- ✓ select_row_by_value detects invalid columns.

🔗 Testing get_columns...

- ✓ get_columns returns a single column correctly.
- ✓ get_columns returns multiple columns correctly.
- ✓ get_columns detects invalid columns.

🔗 Testing aggregate_column...

- ✓ aggregate_column correctly computes maximum.
- ✓ aggregate_column correctly computes minimum.
- ✓ aggregate_column correctly computes mean.
- ✓ aggregate_column detects invalid operations.
- ✓ aggregate_column detects non-existent columns.

🔗 ALL TESTS HAVE BEEN EXECUTED SUCCESSFULLY.

🔗 Testing select_row_by_value...

- ✓ select_row_by_value finds an existing row.
- ✓ select_row_by_value returns None when no match exists.
- ✓ select_row_by_value detects invalid columns.

🔗 Testing get_columns...

- ✓ get_columns returns a single column correctly.

- ✓ get_columns returns multiple columns correctly.
- ✓ get_columns detects invalid columns.

🔗 Testing aggregate_column...

- ✓ aggregate_column correctly computes maximum.
- ✓ aggregate_column correctly computes minimum.
- ✓ aggregate_column correctly computes mean.
- ✓ aggregate_column detects invalid operations.
- ✓ aggregate_column detects non-existent columns.

🏆 ALL TESTS HAVE BEEN EXECUTED SUCCESSFULLY.

5. Evaluación automática (hasta 2 puntos)

- Tras superar la verificación inicial, el fichero será ejecutado también con un **notebook oculto**, siguiendo exactamente las mismas reglas.
- Si el código funciona correctamente en este segundo notebook, el alumno obtendrá **2 puntos sobre 10** de la calificación de la práctica.

6. Evaluación presencial (hasta 8 puntos)

- Después de la fase automática, el alumno realizará en clase un **examen tipo test de 8 preguntas**.
- Las preguntas tratarán **problemas prácticos relacionados con la temática de la práctica**, similares pero **no idénticos** a los ejercidos en el trabajo.
- Las preguntas acertadas suman un punto, las **preguntas falladas restan medio punto** y las no respondidas no cambian la puntuación.
- En esta prueba podrá obtener hasta **8 puntos adicionales**, para un total máximo de **10 puntos**.