

Comparación de LLMs y Prompt Engineering

Clasificación de mensajes de atención al cliente

PROBLEMA ELEGIDO

Clasificación de mensajes de atención al cliente

Tarea: Clasificar mensajes de clientes en 4 categorías.

Categorías: Cuenta · Facturación · Soporte técnico · Logística

Entrada: Texto libre del mensaje del cliente.

Salida esperada: Una única categoría de las 4 posibles.

Medición: Comparación con etiqueta ground-truth (10 mensajes).

¿Por qué este problema?

- Salida discreta → fácil de medir exactitud
- 4 categorías bien diferenciadas
- Tarea real en NLP empresarial
- Permite comparar formato y razonamiento
- Variabilidad medible entre ejecuciones

MODELOS SELECCIONADOS

M
1

BLOOMZ 560M

Configuración de uso:

560M parámetros · Publicado: 03/11/2022

```
pipeline("text-generation", model="bigscience/bloomz-560m")
```

Versión multilingüe e instruction-tuned de BLOOM (xP3). Buen candidato para instrucciones en español.

M
2

SmolLM2 360M Instruct

Configuración de uso:

360M parámetros · Publicado: 04/02/2025

```
pipeline("text-generation", model="HuggingFaceTB/SmolLM2-360M-Instruct")
```

Modelo ultra-compacto de HuggingFace. Fine-tuned para seguir instrucciones. El más ligero del experimento.

M
3

Qwen2.5 0.5B Instruct

Configuración de uso:

0.5B parámetros · Publicado: 19/09/2024

```
pipeline("text-generation", model="Qwen/Qwen2.5-0.5B-Instruct")
```

Familia Qwen2.5 de Alibaba. Instruction-tuned con RLHF. Mejor rendimiento del experimento.

PROMPTS UTILIZADOS

Prompt Base

- 1 Clasifica el siguiente mensaje en una de estas categorías:
Cuenta, Facturación, Soporte técnico, Logística.
Mensaje: "{mensaje}"

Prompt con Plantilla Clara

- 2 Tarea: clasifica un mensaje de atención al cliente.
Contexto: las categorías posibles son exactamente Cuenta, Facturación, Soporte técnico y Logística.
Restricciones: responde con una única categoría; no inventes categorías; no añadas explicación.
Formato de salida: Categoría: <una categoría>
Criterio de calidad: la categoría debe reflejar el problema principal del mensaje.
Mensaje: "{mensaje}"

Prompt con Razonamiento y Contraste

- 3 Analiza el mensaje de atención al cliente y clasifícalo.
Categorías posibles: Cuenta, Facturación, Soporte técnico, Logística.
Instrucciones:
1. Considera brevemente qué categoría encaja mejor.
2. Contrasta al menos dos alternativas si hay duda.
3. Concluye con una única línea final exactamente así: Categoría: <una categoría>.
Mensaje: "{mensaje}"

DISEÑO EXPERIMENTAL

	Prompt Base	Prompt Plantilla	Prompt Razonamiento
BLOOMZ 560M	3 ejecuciones temperature=0.7 max_new_tokens=120	3 ejecuciones temperature=0.7 max_new_tokens=120	3 ejecuciones temperature=0.7 max_new_tokens=120
SmolLM2 360M	3 ejecuciones temperature=0.7 max_new_tokens=120	3 ejecuciones temperature=0.7 max_new_tokens=120	3 ejecuciones temperature=0.7 max_new_tokens=120
Qwen2.5 0.5B	3 ejecuciones temperature=0.7 max_new_tokens=120	3 ejecuciones temperature=0.7 max_new_tokens=120	3 ejecuciones temperature=0.7 max_new_tokens=120

Total: 3 modelos × 3 prompts × 3 ejecuciones = 27 consultas · 10 mensajes con ground-truth anotado

MÉTRICAS DE EVALUACIÓN

OBJETIVAS

1. Exactitud

% categorías correctas vs ground-truth

2. Cumplimiento de formato

Contiene 'Categoría: X' (Sí/No)

3. Categoría válida

La categoría es una de las 4 permitidas

4. Sin explicación extra

Respetar la restricción de brevedad

5. Consistencia

Variabilidad entre las 3 ejecuciones

SUBJETIVAS (escala 1-5)

1. Claridad

¿Es fácil de entender la respuesta?

2. Coherencia

¿El razonamiento es consistente?

3. Utilidad

¿Sirve para clasificar correctamente?

4. Calidad argumentativa

¿Justifica bien la categoría elegida?

5. Adecuación al público

¿Apropiada para un agente de soporte?


RESULTADOS COMPARATIVOS — DATOS REALES

Modelo	Prompt	Exactitud	Formato OK	Consist.	Subj. (1-5)
BLOOMZ 560M	Base	10%	43%	Baja	2.56
BLOOMZ 560M	Plantilla	10%	7%	Media	3.38
BLOOMZ 560M	Razonam.	0%	20%	Baja	3.62
SmolLM2 360M	Base	20%	83%	Baja	3.10
SmolLM2 360M	Plantilla	20%	27%	Baja	4.06
SmolLM2 360M	Razonam.	20%	67%	Baja	4.22
Qwen2.5 0.5B	Base	40%	100%	Media	3.40
Qwen2.5 0.5B	Plantilla	30%	100%	Alta	4.32
Qwen2.5 0.5B	Razonam.	30%	100%	Alta	4.66


* Resultados de ejecución real en Google Colab (GPU T4, temperature=0.7, max_new_tokens=120, 3 repeticiones)

RESULTADOS — EXACTITUD Y FORMATO

Exactitud por modelo y tipo de prompt (resultados reales)



Cumplimiento de formato por modelo y prompt




Observaciones clave

- Qwen2.5 es el único modelo que supera el 30% de exactitud (40% con prompt base, máximo del experimento).
- BLOOMZ alcanza 0% con el prompt de razonamiento — el más complejo lo desestabiliza completamente.
- Qwen2.5 obtiene 100% en cumplimiento de formato en los 3 prompts. BLOOMZ llega a 7% con plantilla.
- SmolLM2 muestra la mayor exactitud con prompt base (83% formato) pero la exactitud real no mejora entre prompts.

VARIABILIDAD DE RESPUESTAS


Variabilidad entre ejecuciones por modelo y prompt




Diversidad media = nº de categorías distintas entre 3 repeticiones (1.0 = todas iguales = perfecta consistencia)

MÉTRICAS SUBJETIVAS

Métricas subjetivas por prompt y modelo (evaluación del grupo)



Métricas subjetivas detalladas por modelo (escala 1-5)



Interpretación

- Las métricas subjetivas mejoran con prompts más estructurados aunque la exactitud objetiva no lo haga.
- El razonamiento genera respuestas más elaboradas y coherentes, valoradas positivamente a pesar de fallar en exactitud.
- Qwen2.5 obtiene 4.66/5 en razonamiento — la calidad percibida es alta aunque la exactitud sea 30%.
- Disociación entre calidad subjetiva y exactitud objetiva: revelan limitaciones de los LLMs pequeños en español.

CONCLUSIONES

1

La exactitud real es baja: modelos pequeños en español

Ningún modelo supera el 40%. La barrera principal es el idioma y el tamaño reducido. BLOOMZ llega a 0% con el prompt de razonamiento.

2

Qwen2.5 0.5B: mejor exactitud y cumplimiento de formato

40% exactitud con prompt base, 100% formato en los 3 prompts. El RLHF de Qwen2.5 se traduce en respuestas más estructuradas aunque la exactitud semántica sea limitada.

3

Disociación entre calidad subjetiva y exactitud objetiva

El prompt de razonamiento mejora la calidad percibida (hasta 4.66/5) pero no aumenta la exactitud. Los modelos razonan bien en forma pero clasifican mal en fondo.

4

El formato del prompt es crítico para la extracción

Sin 'Categoría: X' el extractor falla. BLOOMZ incumple el formato en 93% de los casos con plantilla. El prompt estructura la salida pero no garantiza la semántica.