

INSO & MAIS



Procesamiento de datos

Miguel Ángel Fernández Díaz
2024-2025



Tema 2:

Spark básico

1. Introducción a Big Data

Introducción a procesamiento Big Data



Índice

- Introducción a sistemas distribuidos
 - Historia
 - Conceptos
- Ecosistema Big Data
 - Plataformas


Introducción a sistemas distribuidos



8 March 1939: Some of the four million tickets collected from London Underground passengers are examined in a survey by London Transport to discover the most and least used routes to help future infrastructure development

¿Qué es Big Data?

- 3 Vs
 - Volumen, variedad, velocidad
- ¿o eran 5 Vs?
 - Valor y veracidad
- ¿o eran 7 Vs?
 - Variabilidad y visualización
- NO es BI



Contexto

- RDBMS (Relational Database Management System)
- Páginas Web
- Información desestructurada
- Generación de gran cantidad de información
- Arquitecturas con un único servidor potente
- Migraciones a servidores más grandes
- SPoF (Single Point of Failure)
- HPC (High Performing Computing)
- MPP (Massively Parallel Processing)
- Sistemas distribuidos difíciles de desarrollar
- Cuellos de botella y fallos
- Mover gran cantidad de datos es ineficiente
- Fundación Apache




Contexto

- Localidad del dato
- Computación distribuída
- Tolerancia a fallos
- Replicación
- Elasticidad
- Commodity Hardware
- Google creó el concepto de MapReduce
- Sistemas de ficheros distribuídos: GFS (Google), HDFS (Yahoo!)
- Móvil y Tables = incremento en la generación de eventos
- Información actualizada
- Respuestas en tiempo real




Contexto


- Diversos datos: texto, imágenes, datos estructurados, etc...
- “Code once and deploy at any scale”
- Nutch
- Escenarios multi-usuario
- ¿Big Data = Hadoop?



Gartner Hype Cycle 2011




Gartner Hype Cycle 2014




Contexto

- Buscar vs Desarrollar herramienta adecuada
- Datos estructurados vs datos desestructurados
- NoSQL: Cassandra, Mongo, ES
- BI Tools
- Procesamiento en la nube




Conceptos básicos para entornos distribuidos



Conceptos



- **Procesamiento de datos:**
conjunto de operaciones sobre un grupo de datos para transformarlos de manera que sean útiles para su posterior análisis y visualización.
- **Análisis de datos:** proceso en el cual se recogen ciertos datos de una capa de almacenamiento de datos y, posteriormente, se aplica una serie de operaciones para obtener una serie de valores que conforman un resultado.



Conceptos


- **Procesamiento distribuido:**

- Utiliza múltiples nodos de procesamiento trabajando juntos como parte de un sistema distribuido.
- Los datos se dividen en fragmentos (particiones) más pequeños y se procesan de forma paralela en varios nodos o servidores.



Conceptos


- Arquitectura cliente-servidor



- División de responsabilidades
- Comunicación a través de la red
- Modelo de solicitud-respuesta
- Escalabilidad
- Seguridad
- Independencia de la plataforma
- Desarrollo distribuido

Conceptos


- Clúster de servidores



- Alta disponibilidad
- Escalabilidad
- Balanceo de carga
- Tolerancia a fallos
- Rendimiento
- Administración central
- Seguridad


Conceptos

- Teorema del CAP




Conceptos

- DAG:
 - Representación de tareas
 - Dependencias
 - Acíclico
 - Paralelismo
 - Escalabilidad
 - Tolerancia a fallos



Retos de la concurrencia de usuarios


- Escalabilidad
 - Sin degradación de tiempo
- Disponibilidad
 - Consultas simultáneas
- Balance de carga
 - Evitar cuellos de botella
- Resistencia a fallos
 - Posible saturación
- Tiempo de respuesta
 - Efecto de caja negra



Latencia vs rendimiento

- Latencia
 - Tiempo que tarda una operación específica en completarse
 - Se mide en unidades de tiempo (ms)
 - Latencia baja = respuesta rápida
- Rendimiento
 - Cantidad de trabajo (operaciones) en un periodo determinado de tiempo.
 - Se mide en operaciones por unidad de tiempo (FLOPS)
 - Alto rendimiento = procesar gran cantidad de solicitudes

Network Latency vs. Throughput vs. Bandwidth



OLAP vs OLTP

- Online Analytical Processing
 - Informes sobre datos históricos
 - Los datos se organizan en múltiples dimensiones, como tiempo, producto, ubicación y categoría.
 - Tiempos de respuesta NO “inmediatos”
- Online Transaction Processing
 - Operaciones CRUD en tiempo real
 - Alta concurrencia
 - Tiempos de respuestas rápidos


	OLTP	OLAP
Function	Day to day operation	Decision support
Database Design	Application oriented	Subject oriented
Data	Current, up-to-date detailed, flat relational, isolated	Historical, summarized multi-dimensional, consolidated
Usage	Repetitive	Ad-hoc
Access	Read/Write	Lots of scans
Unit of Work	Short, simple transaction	Complex query
Database Size	Gigabytes	Terabytes
Metric	Transaction throughput	Query throughput, response

Bases de datos NoSQL (Not Only SQL)


- Modelo de datos flexible:
 - Clave-valor, documentos, grafos
- Escalabilidad horizontal
- Alto rendimiento
- Tolerancia a fallos
- Escalabilidad flexible
- Soporte para datos no estructurados y semiestructurados
- Diseño descentralizado
 - SPoF

SQL

Relational




Analytical



NoSQL


Key - Value




Graph




Document



Wide Column



Columnar storage



Nested schema


Logical table representation

a	b	c
a1	b1	c1
a2	b2	c2
a3	b3	c3
a4	b4	c4
a5	b5	c5

Row layout



Column layout



- Almacenamiento por columnas
- Compresión eficiente
- Operaciones selectivas más rápidas
- Mejora de la compresión de datos
- Escaneo eficiente

Conclusiones

- ¿Qué es un sistema distribuido?
 - Un sistema distribuido es un conjunto de componentes de hardware y software que se ejecutan en múltiples nodos interconectados y colaboran entre sí para lograr un objetivo común. Estos sistemas permiten el procesamiento paralelo de datos y la distribución de la carga de trabajo para mejorar el rendimiento y la escalabilidad
- ¿Cuáles son los beneficios de los entornos distribuidos?
 - Algunos de los principales beneficios de los entornos distribuidos incluyen la escalabilidad, la tolerancia a fallos, el rendimiento mejorado y la capacidad de procesar grandes volúmenes de datos de manera eficiente. Estos sistemas también pueden ofrecer una mayor disponibilidad y capacidad de recuperación en comparación con los sistemas centralizados.

Conclusiones

- ¿Cuáles son los desafíos principales de los sistemas distribuidos?
 - Algunos de los desafíos principales incluyen la gestión de la concurrencia y la coherencia de los datos, la tolerancia a fallos, la comunicación y sincronización entre nodos, la seguridad de los datos y la escalabilidad. Además, la complejidad de la programación y el diagnóstico de problemas pueden aumentar en entornos distribuidos.
- ¿Qué estrategias se utilizan para abordar la tolerancia a fallos en sistemas distribuidos?
 - Las estrategias comunes incluyen la replicación de datos para garantizar la disponibilidad y la redundancia, el uso de algoritmos de consenso para lograr la coherencia de datos en presencia de fallos y la implementación de mecanismos de detección y recuperación de fallos automáticos.


Conclusiones

- ¿Cuál es la diferencia entre un sistema distribuido y un sistema paralelo?
 - Aunque ambos tipos de sistemas procesan tareas simultáneamente, la diferencia radica en cómo se organizan y gestionan. En un sistema distribuido, los recursos se encuentran en diferentes ubicaciones físicas y están conectados a través de una red, mientras que en un sistema paralelo, los recursos están centralizados en un único lugar y se comunican a través de buses o interconexiones internas.
- ¿Cuáles son los principales desafíos de la escalabilidad en sistemas distribuidos?
 - Algunos desafíos incluyen el diseño de algoritmos y protocolos que puedan manejar un aumento en el número de nodos y la cantidad de datos, la gestión eficiente de recursos para evitar cuellos de botella y la minimización de la sobrecarga de comunicación y coordinación entre nodos.


Conclusiones

- ¿Qué es la consistencia eventual en sistemas distribuidos?
 - La consistencia eventual es un modelo de consistencia que permite que los diferentes nodos de un sistema distribuido tengan copias diferentes de los datos durante un período de tiempo, pero garantiza que eventualmente converjan a un estado consistente. Este modelo se utiliza para mejorar el rendimiento y la disponibilidad en sistemas donde la coherencia inmediata de los datos no es crítica.
- ¿Cuáles son los principales desafíos al diseñar una arquitectura Big Data?
 - Algunos de los principales desafíos incluyen la gestión de grandes volúmenes de datos, la variedad de fuentes de datos y formatos, la velocidad a la que se generan y procesan los datos, la garantía de la calidad y la integridad de los datos, la seguridad y privacidad de los datos, y la escalabilidad para manejar el crecimiento futuro de datos y usuarios.


Ecosistema Hadoop



- Cloudera



● Stratio



- AWS



● Microsoft Azure

Azure Charts Updates & Trends Overview SLA Status Timeboards Regions Solutions Stories Learning Perspectives About

Azure Services Overview

Overview of Azure services. Linked directly to Azure Service 360° for service summary. Switch to [Advanced View](#)

FOCUS: PaaS

AI + Machine Learning	Analytics	Compute	Databases	Development	Identity + Security	IoT + MR	Integration	Management + Governance	Media + Comms	Migration	Networking	Storage
Applied AI Services	Analysis Services	App Service	Apache Cassandra MI	App Configuration	Azure Active Directory	Azure Maps	API Management	Automation	Azure CDN	Resource Mover	Azure Bastion	Confidential Ledger
Bot Service	Azure Purview	Azure Batch	Cosmos DB	Azure Chaos Studio	Azure AD B2C	Defender for IoT	Energy Data Services	Azure Monitor	Azure Comms. Gateway	Azure Migrate	Azure DNS	Data Lake Storage
Cognitive Search	Data Explorer	Azure Functions	Database for MariaDB	Azure Spring Cloud	Azure AD DS	Digital Twins	Event Grid	Azure Policy	Comm. Services	Data Box	Route Server	Managed Luster
Cognitive Services	Data Factory	Azure Quantum	Database for MySQL	Deployment Environments	Azure Key Vault	IoT Edge	Logic Apps	Kubernetes Fleet Manager	Media Services	DB Migration Service	VNet Manager	Azure VPC
Machine Learning	Data Lake Analytics	Azure Red Hat OpenShift	Database for PostgreSQL	DevTest Labs	Azure Sentinel	IoT Hub	Notification Hubs	Managed Apps		Site Recovery	Application Gateway	Azure Elastic SAN
Project Bonsai	Databricks	Cloud Services	Redis Cache	Lab Services	DDoS Protection	Object Anchors	Service Bus	Azure Advisor			Azure Firewall	Azure NetApp Files
Microsoft Services	Event Hubs	Container Apps	SQL Database	Load Testing	Dedicated HSM	Remote Rendering	Web PubSub	Azure Arc			Azure Front Door	Azure Storage

● Google Cloud

Compute



Compute Engine



App Engine



Container Engine



Container Registry



Cloud Functions

Identity & Security



Cloud IAM



Cloud Resource Manager



Cloud Security Scanner



Cloud Platform Security

Networking



Cloud Virtual Network



Cloud Load Balancing



Cloud CDN



Cloud Interconnect



Cloud DNS

Big Data



BigQuery



Cloud Dataflow



Cloud Dataproc



Cloud Datalab



Cloud Pub/Sub



Genomics

Storage and Databases



Cloud Storage



Cloud Bigtable



Cloud Datastore



Cloud SQL



Persistent Disk

Machine Learning



Cloud Machine Learning



Vision API



Speech API



Natural Language API



Translation API



Jobs API



 Calle Playa de Liencres, 2 bis
(entrada por calle Rozabella)
Parque Europa Empresarial
Edificio Madrid
28290 Las Rozas, Madrid

 900 373 379  info@u-tad.com

 [SOLICITA MÁS INFORMACIÓN](#)



CENTRO ADSCRITO A:



PROYECTO COFINANCIADO POR:

